

TD 6 – Optimisation Réseaux de neuronnes

▷ Exercice 1. On s'intéresse ici à la modélisation via un neurone formel.


Définition 1. Un neurone formel est une fonction paramétrée par n+1 paramètres w_1, \ldots, w_n, b :

$$g: \ \mathbb{R}^n \times \mathbb{R}^n \times \mathbb{R} \ \longrightarrow \ \mathbb{R}$$
$$(x, w, b) \ \longmapsto \ g(x, w, b) \coloneqq \sigma(\sum_{i=1}^n w_i x_i + b)$$

où σ est une fonction donnée qui s'appelle une fonction d'activation. Chaque paramètre w_i s'appelle le poids synaptique associé au signal d'entrée x_i .

On prendra dans la suite, sauf mention contraire, comme fonction σ la fonction sigmoïde :

$$\begin{array}{cccc} \sigma \colon & \mathbb{R} & \longrightarrow & \mathbb{R} \\ & z & \longmapsto & \sigma(z) \coloneqq \frac{1}{1+e^{-z}}. \end{array}$$



La figure 1 schématise un neurone formel.

- 1. produit scalaire entre les entrées x et les poids synaptiques $w: w^T x$;
- 2. ajout d'une valeur de référence (biais b) : $z = w^T x + b$
- 3. application de la fonction d'activation à la valeur obtenue $z: a = \sigma(z)$

Définition 2. On a à notre disposition K points $x^k \in \mathbb{R}^n$ et $y^k \in \mathbb{R}$, on appelle apprentissage du neurone l'estimation par les moindres carrés des paramètres du neurone.

- 1.1. Écrire le problème aux moindres carrés qui défini l'apprentissage. On donnera en particulier la fonction résidu r en précisant clairement l'espace de départ et l'espace d'arrivée.
- **1.2.** Calculer la dérivée de la fonction à minimiser $f(\beta)$.

OPTIMISATION TD 6

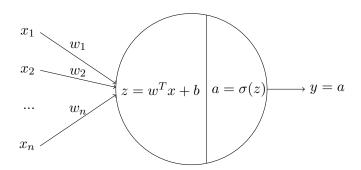


Figure 1 – Représentation schématique d'un neurone.

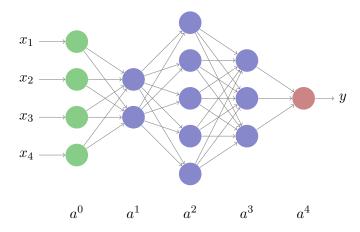


FIGURE 2 – Schéma d'un réseau avec une couche en entré $(a^0 = x)$, 3 couches cachés et une couche en sortie.

- ▶ Exercice 2. On considère maintenant le cas d'un réseau à plusieurs couches données par le schéma de la figure 2.
 - **2.1.** On note L le nombre de couches (sans compter la couche d'entrée), donnez :
 - les nombre de neurones n_l pour $l=1,\ldots,L$ dans chaque couche et la dimension $n_0=n$ des données en entrée;
 - Les dimensions des paramètres W^l et b^l intervenant dans la couche l.
 - **2.2.** On note a^l la sortie de la couche l (a^l s'appelle dans la terminologie des réseaux de neurones l'activation de la couche l). Écrire a^{l+1} en fonction de a^l, W^{l+1}, b^{l+1} et de σ . En déduire la fonction exprimant y en fonction de x et des paramètres du modèle : $y(x, \beta)$.
 - **2.3.** On suppose que l'on a comme données K couples $(x^k, y^k)_{k=1,\dots,K}$, où $x^k \in \mathbb{R}^n$ et $y^k \in \mathbb{R}$. Écrire dans ce cas le problème aux moindres carrés qui définit l'apprentissage.
 - **2.4.** Calculer les dérivées partielles de $y(x,\beta)$ par rapport à $\beta^4 = (W^4, b^4)$ et par rapport à β^3 . En déduire les dérivées partielles de la fonction à minimiser par rapport à ces paramètres β^4 et β^3 .

Remarque 1. En pratique :

- la sortie y est dans \mathbb{R}^{n_L} ;
- On n'utilise pas les moindres carrées, mais une autre fonction de coût;